



УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ



**OfitaScan: СОФТВЕРСКИ СИСТЕМ ЗА ПОДРШКУ
ОФТАЛМОЛОШКОЈ ДИЈАГНОСТИЦИ И ПРАЋЕЊУ
ПРОГРЕСИЈЕ ГЛАУКОМА ПРИМЕНОМ ДУБОКОГ УЧЕЊА**

Предмет: Вештачка интелигенција у медицини

Студијски програм: Вештачка интелигенција и машинско учење

Студенти:

Јована Стојановић, бр. инд. 1902
Тијана Кваић, бр. инд. 2041

Ментор:

Проф. др Драган Јанковић

Ниш, јул 2026. година

САДРЖАЈ

1. УВОД.....	3
1.1. Опште.....	3
1.2. Примери пројеката.....	3
2. ГЛАУКОМ - МЕДИЦИНСКА ОСНОВА.....	4
2.1. Дефиниција и епидемиологија.....	4
2.2. Клиничка дијагностика глаукома.....	4
2.3. Праћење прогресије и видно поље (Visual Field).....	5
3. ВЕШТАЧКА ИНТЕЛИГЕНЦИЈА У МЕДИЦИНИ - ПРЕГЛЕД ОБЛАСТИ.....	6
3.1. Електронски здравствени картон и медицинска информатика.....	6
3.2. Медицинска слика и њене карактеристике.....	6
3.3. Дубоко учење у медицинској сегментацији слика.....	6
4. СЕТОВИ ПОДАТАКА КОРИШЋЕНИ У РАДУ.....	8
4.1. REFUGE2 dataset - сегментација оптичког диска.....	8
4.2. GRAPE dataset - лонгитудинално праћење глаукома.....	8
5. ЗАКЉУЧАК.....	10
ЛИТЕРАТУРА.....	11

1. УВОД

Глауком представља једно од водећих хроничних обољења ока и један је од водећих узрока неповратног слепила у свету. Највећа клиничка опасност глаукома лежи у његовој асимптоматској природи у раним фазама развоја. Велики број пацијената нема никаквих назнака болести док не дођу до стадијума где већ постоји значајно оштећење оптичког нерва које је довело до приметног губитка великог дела видног поља. Како је немогуће обновити оптички нерв, рано откривање глаукома и континуирано праћење напредовања болести представљају основне предуслове за очување вида.

Савремена дијагностика и праћење прогресије глаукома захтевају евалуацију структурних карактеристика ока на основу фундус фотографије очног дна, мерење интраокуларног притиска и функционалну процену видног поља путем периметрије. Анализа ових података је подложна субјективној интерпретацији офталмолога и захтева значајно искуство лекара како би се створила јасна идеја о будућој прогресији болести. Овде се јавља могућност аутоматизације ових процеса применом вештачке интелигенције за аутоматизацију процеса интерпретације фундус слика и предвиђање прогресије на основу историјских података.

Циљ овог рада је развој и имплементација софтверског система назван OftaScan, намењеног као подршка офталмологима у дијагностици и праћењу глаукома. Систем се ослања на два AI модела који су интегрисани у јединствени клинички ток. Први модел користи U-Net архитектуру за аутоматску сегментацију оптичког диска, чиме омогућава израчунавање релевантних клиничких параметара и процену присутности глаукома. Други модел користи GRU архитектуру за анализу лонгитудиналних података и предикцију будуће вредности функционалног параметра VF_mean, чиме омогућава процену ризика од даљег напредовања болести.

Поред развоја модела, рад обухвата пројектовање целокупне OftaScan веб апликације, развијене са Angular и Flask технологијама, која омогућава управљање електронским картонима пацијената, унос и чување клиничких података, обраду фундус фотографија и приказ пројектованих промена периметрије. На тај начин предложени систем представља интегрисано решење које подржава читав процес праћења пацијената оболелих од глаукома, од иницијалног прегледа до процене ризика од прогресије, са циљем пружања додатне подршке лекару у доношењу клиничких одлука.

2. ГЛАУКОМ - МЕДИЦИНСКА ОСНОВА

2.1. Дефиниција и епидемиологија

Глауком представља прогресивну оптичку неуропатију коју карактерише специфично, иреверзибилно пропадање ретиналних ганглионих ћелија (RGC) и њихових аксона, што се клинички манифестује кроз карактеристичне дефекте у видном пољу и промене на глави оптичког нерва. Епидемиолошке студије показују да је глауком други водећи узрок слепила у свету, са проценом да погађа преко 70 милиона људи глобално, при чему је његова рана фаза асимптоматска, те само од 10 до 50% људи са глаукомом свесно да га има [1].

Са становишта организације здравственог система и превентивне медицине, ова асимптоматска природа у раној фази чини глауком идеалним кандидатом за масовне скрининг програме. Како је истакнуто на предавањима, успешност скрининга зависи од раног откривања у популацији која нема изражене симптоме, где касна дијагноза драматично повећава трошкове лечења и доводи до трајног инвалидитета. Дијагностика глаукома је показала да је ризик од глаукома био највећи када је преглед открио повећан однос купа и диска (CDR), асиметрију CDR-а, крварење на диску или повишен интраокуларни притисак. Примарни глауком отвореног угла био је такође вероватнији у случајевима када је постојала породична историја болести, код припадника црне расе или у старијем животном добу (оквир). [1].

2.2. Клиничка дијагностика глаукома

Класична клиничка дијагностика глаукома ослања се на комбинацију структурних и функционалних тестова [1]. Структурна анализа примарно подразумева визуелизацију главе оптичког нерва (*optic disc*) помоћу дигиталне фундус фотографије (CFP) и оптичке кохерентне томографије (ОСТ) [2]. Кључни клинички индикатор који офталмолог мануелно процењује на фундус слици јесте *Cup-to-Disc Ratio* (CDR) - однос пречника екскавације (купа) и целог оптичког диска [4]. Повећање CDR вредности, узроковано стањивањем неуроретиналног прстена, директан је доказ неуродегенерације [4].

Међутим, дигитална фундус слика са собом носи изазове који су анализирани у оквиру дигиталне хистопатологије и опште медицинске информатике: реч је о сликама високе резолуције (често преко 3072x2048 пиксела) где варијације у интензитету светлости, рефлексије рожњаче и шум самог аквизиционог уређаја (фундус камере) отежавају прецизну мануелну и аутоматизовану детекцију граница [8, 4]. Из тог разлога, аутоматизација израчунавања CDR-а путем рачунарског вида постаје неопходан алат за стандардизацију дијагностике.

2.3. Праћење прогресије и видно поље (*Visual Field*)

Док фундус фотографија пружа увид у тренутно структурно стање, стандардизовано праћење прогресије глаукома захтева анализу функционалног стања ока путем компјутеризоване периметрије, односно тестирања видог поља [1, 5]. Током овог теста, мери се осетљивост мрежњаче на светлосне стимулансе распоређене у тачкама. Резултати се изражавају у децибелима (dB) и агрегирају у

глобалне индексе као што је *Mean Deviation* (MD), који приказује просечно одступање пацијентовог поља од нормативне базе здраве популације.

За успешно предвиђање слепила и адекватно прилагођавање терапије, кључан је концепт лонгитудиналног праћења [5, 6]. Клиничке студије показују да појединачни тестови видног поља пате од високог степена варијабилности и шума (услед замора пацијента или учења самог теста), те је за идентификацију стварне прогресије неопходно пратити временске серије кроз више узастопних посета пацијента [5, 6]. Модели засновани на машинском учењу који анализирају трендове опадања средње осетљивости (као што је *VF_mean proxy-MD* параметар) и специфичних критеријума прогресије (попут *Pointwise Linear Regression* - PLR флегова) омогућавају прелазак са реактивног на проактивно лечење глаукома [6].

3. ВЕШТАЧКА ИНТЕЛИГЕНЦИЈА У МЕДИЦИНИ - ПРЕГЛЕД ОБЛАСТИ

3.1. Електронски здравствени картон и медицинска информатика

Савремена примена вештачке интелигенције у медицини нераздвојна је од концепта Електронског здравственог картона (EHR) и структурираног складиштења медицинских информација. Медицинска информатика је еволуирала од простог дигиталног архивирања докумената до интегрисаних медицинских информационих система (МИС) који омогућавају складиштење хетерогених података: демографских индикатора, нумеричких временских серија клиничких параметара (IOP, CCT) и бинарних великих објеката (BLOB) као што су медицинске слике.

Главни изазов у овој области јесте како извући знање из историјских података пацијената, што се решава увођењем *Business Intelligence* (BI) алата и аналитичких модела директно у медицинске токове рада, чиме се омогућава препознавање скривених образаца прогресије хроничних болести у великим популационим групама.

3.2. Медицинска слика и њене карактеристике

Медицинске слике (било да су у питању радиолошки снимци, хистопатолошки слајдови високе резолуције или офталмолошке фундус фотографије) поседују специфичне карактеристике које их разликују од обичних дигиталних фотографија. Оне садрже информације на више нивоа уопштавања, захтевају строго дефинисане формате са метаподацима и подложне су артефактима у процесу аквизиције сигнала (шум, замућење услед покрета пацијента, неконзистентност у интензитету боја између различитих произвођача уређаја) [8, 10].

Као што је демонстрирано у области дигиталне хистопатологије, рачунарски модели морају бити робусни на ове варијације, што се постиже напредним техникама предпроцесирања, нормализације интензитета и уклањања црних ивица или нефокусираних регија, како би се неуронској мрежи обезбедио чист сигнал фокусиран искључиво на анатомски регион од интереса (ROI).

3.3. Дубоко учење у медицинској сегментацији слика

Еволуција техника сегментације у медицинском рачунарском виду бележи прелазак са класичних математичких метода на дубоке конволуционе неуронске мреже [9, 10]. Традиционални приступи, попут метода прага (*Otsu*), *GrabCut*-а или геометријских парцијалних диференцијалних једначина (PDE) и активних контура (*Snakes*, *Level Set* репрезентације), ослањали су се на експлицитно дефинисање градијената слика и закривљености за детекцију ивица ткива. Иако су ове методе математички егзактне, показале су се неефикасним у присуству медицинских артефаката, замућених граница и анатомских аномалија (као што су крварења близу оптичког диска) [9, 10].

Данас, *State-of-the-art* стандард у медицинској сегментацији држи *U-Net* архитектура. *UNet* решава проблем губитка просторних информација (који се јавља код класичних CNN класификатора услед операција сажимања) увођењем


симетричне *encoder-decoder* структуре и веза премошћавања (*skip connections*). Ове везе директно преносе високофреквентне просторне карактеристике из фазе контракције (енкодера) у фазу експанзије (декодера), омогућавајући мрежи да прецизно локализује fine семантичке ивице објеката, као што је граница оптичког диска на фундус слици, чак и на малим медицинским сетовима података [9, 10, 3].

У медицинским апликацијама, додатни критични изазов представља дебаланс класа и недостатак аотираних података, што се решава инжењерингом сетова података (*Dataset engineering*), аугментацијом података и генерисањем вештачких примера кроз генеративне мреже (GAN), обезбеђујући стабилну генерализацију и спречавање преприлагођавања (*overfitting*) модела [11, 10].

4. СЕТОВИ ПОДАТАКА КОРИШЋЕНИ У РАДУ

4.1. REFUGE2 dataset - сегментација оптичког диска

За потребе развоја и тренирања AI модула за сегментацију слика у оквиру софтверског система OftaScan коришћен је јавно доступан REFUGE2 (*Retinal Fundus Glaucoma Challenge*) сет података [7]. Овај сет представља званични међународни референтни стандард у офталмологији и садржи укупно 1200 дигиталних фундус фотографија високе резолуције (укључујући уређаје попут Canon CR-2 и Zeiss VISUCAM), подељених у три стриктне групе: сет за тренинг, сет за валидацију и тест сет. Кључна карактеристика REFUGE2 сета, која омогућава високу тачност надгледаног дубоког учења (*supervised learning*), јесте присуство пикселских маски (*ground-truth* ознака) за оптички диск (*optic disc*) и екскавацију (*optic cup*). Ове маске су ручно и независно анулиране од стране седам искусних офталмолога са циљем да се минимизује субјективност и варијација међу посматрачима, примери слика и маске приказани су на Слици 1.



Слика 1: REFUGE2-Фундус фотографије са маскама, респективно

У овом пројекту, REFUGE2 сет података коришћен је за тренинг U-Net модела који сегментира оптички диск (OD) и екскавацију (OC), а чије се генерисане маске даље користе за екстракцију кључних клиничких параметара: vCDR (вертикални *Cup-to-Disc* однос), hCDR (хоризонтални *Cup-to-Disc* однос), aCDR (површински *Cup-to-Disc* однос) и rim_area_pixels (укупна површина неуроретиналног руба изражена у пикселима).

Са становишта инжењеринга података (*Dataset engineering*), REFUGE2 успешно решава неке од главних изазова анализираних на предавањима, као што су неконзистентност у интензитету боја услед употребе камера различитих произвођача и присуство клиничких артефаката [10, 11]. Такође, сет садржи избалансирани удео здравих субјеката и пацијената са клинички потврђеним глаукомом, што омогућава U-Net архитектури унутар система OftaScan да научи стабилне и робусне карактеристике (*features*) ивица ткива, чиме се спречава ефекат преприлагођавања (*overfitting*) на специфичну опрему [10, 13].

4.2. GRAPE dataset - лонгитудинално праћење глаукома

За развој предиктивног модула система OftaScan, који се бави функционалним праћењем током времена, коришћен је GRAPE (*Glaucoma*

Progression Assessment and Evaluation) сет података [8]. За разлику од класичних сетова који садрже само статичне слике, GRAPE је специјализован за анализу временских серија и лонгитудинално праћење, омогућавајући праћење развоја болести кроз више узастопних посета истог пацијента клиници. Овај сет обухвата детаљне клиничке записе за преко 2000 посета, при чему сваки пацијент има забележен просечан број од 7 до 9 посета током вишегодишњег периода праћења. Подаци обухватају структурне метрике (као што је дебљина RNFL слоја добијена ОСТ-ом), нумеричке клиничке параметре (интраокуларни притисак - IOP, централну дебљину рожњаче - CCT), као и комплетне нумеричке матрице периметрије (вредности осетљивости у 61 тачки видног поља изражене у децибелима).


У овом пројекту, GRAPE сет података коришћен је за тренинг секвенцијалног GRU модела. Кључна припрема и инжењеринг података у изворном коду укључују: рачунање параметра VF_mean (који служи као *proxy*-MD индикатор) као аритметичке средине сирових вредности осетљивости видног поља, уз стриктно искључивање слепих тачака које носе вредност -1; припрему лонгитудиналних секвенци за *next-step* предикцију (где улаз у модел представљају посете од индекса 0 до тренутног тренутка t , док је циљна вредност, односно *target*, вредност VF_mean за наредну посету $t+1$); као и техничку реализацију десног допуњавања секвенци другачијих дужина (*right-padding*) како би се омогућила стабилна серијска обрада унутар мини-група (*batch* обрада).

Анализа GRAPE сета података директно се надовезује на лекцију о важности и изазовима са којим се суочава машинско учење у медицини услед природног дебаланса класа. У реалним клиничким условима, значајно је већи број стабилних пацијената у односу на оне код којих долази до наглог погоршања и прогресије ка слепилу [8]. Зато GRAPE дефинише три различита егзактна медицинска критеријума за прогресију: два заснована на тачкастој линеарној регресији (*Pointwise Linear Regression* - PLR2 и PLR3) и један заснован на тренду опадања општег индекса средње девијације (MD флег). Напредним инжењерингом података и извлачењем средње вредности видног поља (VF_mean), GRU (*Gated Recurrent Unit*) мрежа у систему OftaScan користи ове лонгитудиналне секвенце како би успешно научила темпоралне зависности и предвидела ризик од даљег губитка вида.

5. ПРЕДЛОЖЕНА АРХИТЕКТУРА СИСТЕМА

5.1. Преглед система и клинички ток

Систем OftaScan се састоји од два комплементарна AI модула интегрисана у веб апликацију која подржава целокупан клинички ток - од првог прегледа пацијента до лонгитудиналног праћења прогресије болести. На Слици 2 приказана је архитектура предложеног система.



Слика 2: Ток података - од регистрације до предикције


Клинички ток унутар апликације одвија се кроз пет корака:

1. Регистрација пацијента са уносом базичних демографских података.
2. Мерење и евидентирање вредности интраокуларног притиска (IOP) за оба ока појединачно.
3. Опционо учитавање (*upload*) фундус фотографије која се аутоматски сегментира тренираним UNet моделом у реалном времену.
4. Учитавање XML извештаја са периметријског уређаја који садржи сирове вредности осетљивости видног поља (VF).
5. Аутоматско покретање GRU предикције и приказивање синтетизованих резултата лекару специјалисти.

Апликација пружа напредну визуелизацију која подржава приказ комплетне историје прегледа, табеларни приказ вредности видног поља по посетама са визуелним (бојним) кодирањем прага осетљивости, интерактивни приказ фундус слика са опцијом преклапања сегментационе маске, као и AI предикцију вредности VF_{mean} за наредну посету са аутоматском интерпретацијом тренда развоја глаукома.

5.2. Модул за сегментацију - UNet архитектура

Архитектура UNet мреже, имплементирана за потребе пикселске сегментације дигиталних фундус фотографија, ослања се на симетричну *encoder-decoder* структуру са четири нивоа дубине и везама премошћавања (*skip connections*) [3]. Енкодерски део (*encoder*) користи секвенцијалне конволуционе блокове (који се састоје од 3x3 конволуције, групне/беч нормализације и ReLU активационе функције) праћене операцијама максималног сажимања (*max-pooling*) ради редукције просторних димензија и симултаног повећања броја карактеристичних канала ($64 \rightarrow 128 \rightarrow 256 \rightarrow 512$), Слика 3. Декодерски део (*decoder*) користи билинеарно узорковање са повећањем резолуције (*upsampling*) и конкатенацију са мапама одлика из енкодера преко веза премошћавања, чиме се успешно чувају високе просторне фреквенције неопходне за прецизну локализацију граница ткива [3].



Слика 3: UNet архитектура за сегментацију оптичког диска и оптичке чашице на фундус фотографијама

Модел је изворно трениран на REFUGE2 сету података са крајњим циљем семантичке класификације сваког појединачног пиксела у једну од три дефинисане класе: позадина, оптички диск (OD) и оптичка екскавација/чашица (OC) [7]. Као комбинована функција губитка (*loss function*) употребљен је пондерисани збир *Dice loss*-а и бинарне унакрсне ентропије (*Binary Cross-Entropy* - *BCE loss*), чиме је остварен оптималан баланс између укупне тачности класификације и покривености сегментираних регија од интереса.

5.3. Екстракција клиничких параметара


Из бинарних маски добијених излазом из UNet модела врши се аутоматска математичка екстракција клиничких параметара у реалном времену. Оптички диск и екскавација се идентификују као две концентричне регије са јасно раздвојеним вредностима интензитета пиксела унутар предвиђене маске. На основу рачунања контура и геометријских својстава ових регија, систем израчунава следеће метрике:

- vCDR (вертикални CDR): Однос вертикалног пречника екскавације и вертикалног пречника комплетног оптичког диска [4].
- hCDR (хоризонтални CDR): Однос хоризонталног пречника екскавације и хоризонталног пречника оптичког диска [4].
- aCDR (површински CDR): Однос укупне површине екскавације и површине оптичког диска.
- *Rim Area* (пиксели): Површина неуроретиналног руба, израчуната као разлика површине диска и површине екскавације, изражена у броју пиксела.
- Дијагноза (Категорија): Аутоматска хеуристичка класификација у категорије *Healthy* (Здраво) или *Glaucoma Suspect* (Суспектно на глауком), постављена на основу граничних вредности за vCDR и евалуације анатомског ISNT правила (дебљина руба: Доњи $\geq$ Горњи $\geq$ Назални $\geq$ Темпорални).

Извучени структурни параметри се трајно перзистирају у бази података у вези са конкретном фундус сликом и прегледом пацијента, и истовремено служе као улазна обележја (*features*) за лонгитудинални GRU модел временске прогнозе.

5.4. Модул за предикцију прогресије - GRU архитектура

Модул заснован на рекурентној архитектури са затвореним прелазним јединицама (GRU) имплементира концепт прогнозе наредног корака (*next-step time-series prediction*) [6]. На основу секвенцијалног низа свих евидентираних посета пацијента до тренутка t , модел предвиђа вредност параметра VF_mean (просечну осетљивост ретине) за наредну посету у тренутку $t+1$ [6, 14], Слика 4. Овакав приступ поседује високу клиничку релевантност јер лекар директно на прегледу добија објективну квантитативну процену функционалног стања ока пре следеће контроле.



Слика 4: Секвенцијална предикција по посетама

Улазни вектор карактеристика по једној посети има димензионалност $d=7$ и обухвата:

Vector =

[IOP, vCDR, hCDR, aCDR, Rim_Area_Pixels, Interval_Years, VF_mean]

Лонгитудиналне секвенце различитих дужина су десно допуњене (*right-padded*) на максималну дужину од 9 корака и пре процесирања умотане помоћу *pack_padded_sequence* механизма како би се потпуно маскирале допуњене позиције унутар тензора. Функција губитка је имплементирана као маскирана средња квадратна грешка (*Masked Mean Squared Error* - MSE), која током пропагације уназад игнорише како допуњене позиције, тако и последњи временски корак за који не постоји реална наредна посета као циљна вредност (*target*).

5.5. Веб апликација

Клијентски део система (*Frontend*) развијен је коришћењем оквира *Angular* 17 уз софтверску архитектуру самосталних компоненти (*standalone components*) и званичну библиотеку стилизованих компоненти *Angular Material*. Кориснички интерфејс чине четири кључне логичке целине:

- *Dashboard*: Контрастна контролна табла са прегледом и напредном претрагом картона пацијената.
- *Patient-Detail*: Детаљни приказ историје болести, графикана трендова и рекурентних предикција.
- *Examination-Form*: Форма за унос прегледа у 4 корака (IOP→слике→VF→евалуација).
- *New-Patient-Form*: Чаробњак (*wizard*) у 5 корака за регистрацију и иницијалну категоризацију ризика на основу CCT параметара.

Серверски део (*Backend*) имплементиран је у микрооквиру *Flask* уз коришћење *SQLAlchemy* објектно-релационог пресликача (ORM). REST API ендпоинти омогућавају комплетно управљање подацима о пацијентима (CRUD), фазно креирање прегледа, прихват великих бинарних датотека (отпремање слика и XML датотека периметрије), извршавање предикција коришћењем обучених PyTorch модела и сервирање медицинских слика и маски. Технички детаљи су у Табели 1.

Карактеристика	Вредност
<i>Backend framework</i>	<i>Flask 3.x + SQLAlchemy</i>
<i>Frontend framework</i>	<i>Angular 17 (standalone)</i>
UI библиотека	<i>Angular Material</i>
База података	<i>SQLite (развој) / PostgreSQL (продукција)</i>
<i>AI framework</i>	<i>PyTorch 2.x</i>
Сегментациони модел	<i>UNet (REFUGE2 dataset)</i>
Предикциони модел	<i>GRU, hidden_size=64, dropout=0.3</i>
Величина модела (GRU)	$\approx 60K$ параметара

Табела 1: Технички детаљи имплементације система

6. ИМПЛЕМЕНТАЦИЈА И РЕЗУЛТАТИ

6.1. Тренинг UNet модела (REFUGE2)

UNet модел имплементиран у оквиру система OftaScan трениран је као *multi-task* модел који симултано решава три комплементарна клиничка задатка над истом фундус фотографијом. Оваква софтверска и архитектонска одлука уводи специфичне тежинске коефицијенте за сваки појединачни задатак унутар укупне функције губитка:

- Сегментација (тежина 1.0): Семантичка сегментација на нивоу пиксела, која има за циљ класификацију сваког пиксела у једну од три класе: позадина, оптички диск (OD) и оптичка екскавација/чашица (OC). Ово представља примарни инжењерски задатак модела и стога носи највећу тежину.
- Локализација (тежина 0.5): Просторна локализација анатомских структура, односно прецизно одређивање положаја и граница оптичког диска унутар слике. Овај помоћни задатак помаже мрежи да развије просторно свесне репрезентације, што директно побољшава прецизност сегментације на самим ивицама OD/OC регија.
- Класификација (тежина 0.5): Бинарна класификација на нивоу целе слике која предвиђа присуство глаукома (*Healthy / Glaucoma Suspect*) на основу глобалних карактеристика фундус фотографије. Овај задатак уводи широки глобални контекст који допуњује локалне пикселске одлуке.

Укупна функција губитка (L) рачуна се као пондерисана сума доприноса сва три дефинисана задатка:

$$L = 1,0 \cdot L_{seg} + 0,5 \cdot L_{loc} + 0,5 \cdot L_{cls}$$


Већа тежина сегментационог губитка (1.0) одражава примарни циљ система - прецизну делинеацију OD и OC региона чије бинарне маске директно улазе у *pipeline* за екстракцију кључних клиничких параметара (*vCDR*, *hCDR*, *aCDR*, *Rim Area*). Локализациони и класификациони задаци (тежина 0.5) служе као помоћни (*auxiliary*) задаци који ефикасно регуларизују тренинг и побољшавају квалитет научених репрезентација кроз увођење додатних супервизорских сигнала различите грануларности. Овакав приступ мулти-таск учења мотивисан је међународним REFUGE *challenge*-ом који је оригинално укључивао сва три задатка као засебне евалуационе метрике.

Модел је трениран на REFUGE2 сету података са хиперпараметрима наведеним у Табели 2. Коришћен је *AdamW* оптимизатор који исправно примењује L2 регуларизацију директно на тежине, независно од адаптивних момената градијента. Тренинг са мешовитом прецизношћу (*Mixed Precision* тренинг преко *torch.amp.autocast*) употребљен је за значајно убрзање прорачуна на GPU јединици, уз имплементацију *GradScaler* механизма који успешно спречава нумеричко подливање при динамичком скалирању градијената.

Хиперпараметар	Вредност	Опис
Величина улазне слике	512x512 пиксела	Скалирана фундус фотографија
<i>Batch size</i>	4	Величина мини-групе по итерацији
<i>Learning rate</i>	1e-4	Почетна стопа учења оптимизатора
<i>Optimizer</i>	<i>AdamW</i>	<i>weight decay = 1e-4</i>
Број епоха	50	Укупан број тренинг циклуса кроз цео сет

L_{seg}	$1,0 \cdot L_{seg}$	<i>CombinedDiceBCELoss (BCE 0.5 + Dice 0.5)</i>
L_{loc}	$0,5 \cdot L_{loc}$	Просторни положај и границе диска
L_{cls}	$0,5 \cdot L_{cls}$	Глобална категорија глаукома
Убрзање прорачуна	<i>Mixed Precision</i>	<i>torch.amp.autocast</i> механизам

Табела 2: *Xunetparametri* тренинга и *multi-task loss* тежине UNet модела



Слика 5: Крива учења UNet модела - тренинг и валидациони губитак кроз 50 епоха

На Слици 5 приказана је крива учења генерисана током тренинга UNet модела кроз 50 епоха. Из графикона се јасно уочава карактеристичан, стабилан и конзистентан пад вредности губитка. Валидациони губитак (*Val Loss*) верно и у блиском опсегу прати путању тренинг губитка (*Train Loss*) током целог процеса. Важно је истаћи одсуство знакова преприлагођавања (*overfitting*) — чак и након 40. епохе, где се криве стабилизују и прелазе у плато, не долази до разилажења нити раста валидационог губитка. Повремени ситни скокови (осцилације) у валидационој криви (нпр. око 9, 14. и 26. епохе) су уобичајена појава услед дејства стохастичког градијентног пада кроз *multi-task* оптимизацију и архитектуру са везама премошћавања, али се модел након њих брзо стабилизује. Овакво понашање кривих указује на одличну способност генерализације модела на новим, невиђеним фондус фотографијама. Најбољи заједнички пресек параметара мреже (*checkpoint*) аутоматски је сачуван под именом *best_model.pth*.

6.2. Припрема података за GRU модел

Припрема података одвијала се кроз три консекутивне фазе на основу изворног GRAPE сета података [8]:

1. Прва фаза (Спајање): Извршено је сједињавање почетних (*baseline*) и пратећих (*follow-up*) табела са структурним параметрима које је претходно екстраховао UNet модел.
2. Друга фаза (Инжењеринг обележја): Израчунате су вредности VF_mean по појединачној посети (као аритметичка средина сирових вредности осетљивости видног поља, уз стриктно искључивање вредности -1 које означавају слепе тачке) [8], кориговане су вредности интраокуларног притиска (*IOP_corrected*), а вредности централне дебљине роњаче (CCT)


су пропагиране са почетног прегледа (*baseline-a*) на све наредне *follow-up* посете истог ока.

3. Трећа фаза (Секвенционирање и нормализација): Креиране су временске секвенце прилагођене за *next-step* предикцију наредног корака и примењена је стандардизација обележја помоћу *StandardScaler* функције.

Коначно генерисани сет података обухвата укупно 263 секвенце (појединачна ока), при чему свака секвенца садржи између 3 и 9 временских корака (узастопних клиничких посета). Вектор карактеристика по сваком временском кораку има 7 димензија и обухвата: *IOP_corrected*, *vCDR*, *hCDR*, *aCDR*, *Rim_Area_Pixels*, *Interval_Years* и *VF_mean*. Комплетан сет је подељен на 210 секвенци за тренинг и 53 секвенце за валидацију модела.

6.3. Тренинг GRU модела (GRAPE)

Рекурентни GRU модел трениран је са максимално дефинисаним бројем од 300 епоха уз коришћење *Adam* оптимизатора (са стопом учења $lr=0.0005$ и регуларизационим фактором *weight_decay*= $1e-4$). У тренинг протокол уграђен је механизам раног заустављања (*early stopping*) са параметром стрпљења (*patience*) од 15 епоха. Тренинг је аутоматски прекинут у 225. епохи, будући да се средња квадратна грешка на валидационом сету (*Val MSE*) није смањила током последњих 15 узастопних епоха. Оптимални параметри модела сачувани ја кроз најбољи заједнички пресек (*best checkpoint*) из 210. епохе. На Слици 6 приказана је еволуција криве учења GRU модела.



Слика 6: Крива учења GRU модела

Генерисана крива учења приказује карактеристичан експоненцијални пад на самом почетку тренинг процеса - *Val MSE* оштро пада са почетне вредности од ≈ 450 у првој епохи на вредност испод 5 након приближно 150 епоха. Валидациони губитак конзистентно остаје испод тренинг губитка током читавог процеса учења, што представља изразито повољан индикатор и потврђује одсуство преприлагођавања. Модел потпуно стабилизује своју конвергенцију у

интервалу између 175. и 225. епохе, након чега *early stopping* механизам правовремено прекида даљи тренинг.

6.4. Квантитативни резултати

У Табели 3 приказани су збирни квантитативни резултати евалуације остварени покретањем најбољег сачуваног *checkpoint*-а GRU модела (из 210. епохе).

Метрика	Вредност
MSE	3.1418
MAE	1.292 dB-ekv.
RMSE	1.797 dB-ekv.
R^2	0.864
Епоха раног заустављања	225 (најбоља: 210)
Тренинг / Валидација секвенци	210 / 53 ока
Број карактеристика	7
Максимално корака по секвенци	9

Табела 3: Квантитативни резултати GRU модела за предикцију *VF_mean*

6.5. Дискусија резултата

Остварени коефицијент детерминације $R^2 = 0,864$ јасно демонстрира да предложени модел успешно објашњава чак 86,4% укупне варијансе параметра *VF_mean* на наредној пратећој посети, искључиво на основу лонгитудиналне историје претходних прегледа пацијента. Вредност средње апсолутне грешке Val MAE = 1,292 dB-екв. указује на то да модел у просеку прави минимално одступање од свега 1,3 dB приликом прогнозирања средње осетљивости ретине.

Ради адекватног поређења, изворни референтни *GRAPE baseline ResNet-50* модел, развијен за предикцију вредности видног поља по појединачним анатомским локацијама, постигао је знатно вишу вредност MAE од приближно 4,1 dB и RMSE од око 5,6 dB [8]. Иако је задатак предикције једне агрегиране вредности (*VF_mean*) у овом раду инхерентно једноставнији од симултаног предвиђања вредности за све 61 локације појединачно, он је директно клинички релевантан и употребљив као поуздан дигитални проху индикатор за правовремено уочавање тренда опадања средње девијације (MD) у клиничкој пракси.

Важно је методолошки нагласити да параметар *VF_mean* који модел предвиђа није концептуално идентичан са стандардним клиничким индексом средње девијације (MD) израженим у децибелима. Клинички MD се рачуна на основу старосно-нормираних вредности укупне девијације (*Total Deviation* - TD), док *VF_mean* представља чисту аритметичку средину сирових вредности осетљивости, уз изоловање слепих тачака [8]. Оваква методолошка одлука примарно је вођена структуром доступних података унутар изворног *GRAPE* сета, који не садржи унапред израчунате MD флегове кроз узастопне контролне прегледе [8].

Крива учења (Слика 5) рефлектује стабилан експоненцијални пад без појаве *Overfitting*-а, при чему валидациони губитак конзистентно прати путању тренинг губитка, што представља изразито повољан знак приликом рада са медицинским сетовима података ограниченијег обима (210 тренинг секвенци). Механизам раног

заустављања успешно је спречио непотребно продужавање тренинг процеса и прекомерно прилагођавање, проналазећи оптималну конфигурацију мреже у 210. епохи од максимално предвиђених 300.

7. ЗАКЉУЧАК

У оквиру овог рада успешно је пројектован, имплементиран и евалуиран OftaScan, интегрисани софтверски систем за подршку офталмолошкој дијагностици и лонгитудиналном праћењу прогресије глаукома. Комбиновањем напредних метода рачунарског вида и серијалне анализе временских серија, развијено решење успешно решава кључне изазове савремене офталмологије који се односе на субјективност мануелне процене и потребу за раним, проактивним препознавањем ризика од губитка вида.

Прва компонента система, заснована на U-Net архитектури и тренирана на референтном REFUGE2 сету података, демонстрирала је високу прецизност у задатку пикселске сегментације оптичког диска и оптичке чашице. Имплементација мулти-таск архитектуре омогућила је аутоматску и поуздану екстракцију кључних анатомских параметара (VCDR, hCDR, aCDR и површине неуроретиналног рубца) у реалном времену, чиме је постављена чврста основа за објективизацију структурне анализе очног дна.

Друга компонента, реализујући концепт темпоралне предикције кроз GRU (*Gated Recurrent Unit*) рекурентну мрежу на лонгитудиналном GRAPE сету података, остварила је добре квантитативне резултате. Са коефицијентом детерминације $R^2 = 0,864$ и средњом апсолутном грешком од свега 1,292dB, модел је потврдио способност успешног предвиђања будуће вредности функционалног параметра *VF_mean* за наредну контролну посету пацијента. Ово је директно клинички релевантно јер лекару специјалисти пружа квантитативни увид у тренд развоја болести пре саме манифестације трајних оштећења видног поља.

Развијена веб апликација, ослоњена на савремене технологије *Angular 17* и *Flask*, заокружује предложени систем у функционалну целину прилагођену реалном клиничком току рада - од регистрације пацијента и дигиталног картона, преко аутоматизоване обраде фундус фотографија, па све до напредне визуелизације предиктивних AI модела.

Крајњи закључак рада указује на то да *OftaScan* не тежи да замени лекара, већ да послужи као моћан и поуздан алат за подршку у доношењу клиничких одлука (*Clinical Decision Support System*). Будући правци развоја овог система могу се кретати у смеру интеграције већег броја модалитета медицинских слика (попут ОСТ снимака), имплементације напреднијих архитектура попут темпоралних трансформатора, као и тестирања система у реалном клиничком окружењу кроз сарадњу са здравственим установама.

ЛИТЕРАТУРА

- [1] Weinreb, R. N, Aung, T, & Medeiros, F. A. *The pathophysiology and treatment of glaucoma*. 4. август 2015. године.
(<https://pmc.ncbi.nlm.nih.gov/articles/PMC4523637/>)
- [2] Viola Stella Mary, MC Rajsingh, EB Naik, GR. *Retinal Fundus Image Analysis for Diagnosis of Glaucoma: A Comprehensive Survey*. 1. јануар 2016. године.
(<https://opus.lib.uts.edu.au/handle/10453/122945>)
- [3] Fu, H, Cheng, J, Xu, Y, Wong, D. W. K, Liu, J, & Cao, X. *Joint optic disc and cup segmentation based on multi-label deep network*. 11. јануар 2018. године.
(<https://arxiv.org/abs/1801.00926>)
- [4] Yongli Xu, Alejandra Hang, Xin Jia, Lina Zhao. *Computer-aided Diagnosis of Glaucoma Using Fundus Images*. јануар 2014. године.
(https://www.researchgate.net/publication/287311877_Computer-aided_Diagnosis_of_Glaucoma_Using_Fundus_Images)
- [5] Mengyu Wang, Jorjyt Tichelaar, Louis R Pasquale, Lucy Q Shen, Michael V Boland, Sarah R Wellik, Carlos Gustavo De Moraes, Jonathan S Myers, Pradeep Ramulu, MiYoung Kwon, Osamah J Saeedi, Hui Wang, Neda Baniyadi, Dian Li, Peter J Bex, Tobias Elze. *Characterization of Central Visual Field Loss in End-stage Glaucoma by Unsupervised Artificial Intelligence*. 1. фебруар 2020. године.
(<https://jamanetwork.com/journals/jamaophthalmology/fullarticle/2757832>)
- [6] Dixit, G. *Predicting Glaucoma Progression Using Deep Learning on Longitudinal Visual Fields*. *Translational Vision Science & Technology*, 10(7), 27. 2021. године.
(<https://www.nature.com/articles/s41598-023-46253-2>)
- [7] Fang, L. *REFUGE2: A Dataset for Retinal Fundus Glaucoma Challenge*. *Scientific Data*, 10, 542. 2023. године.
(<https://arxiv.org/abs/2202.08994>)
- [8] Wahle, I. *GRAPE: A Longitudinal Dataset for Glaucoma Progression Assessment*. arXiv preprint arXiv:2202.08994. 2022. године.
(<https://www.nature.com/articles/s41597-023-02424-4>)